



第3章 数据预处理

目录 CONTENTS

3.1

数据存在的问题

3.2

数据清理

3.3

数据集成

3.4

数据归约

3.5

数据变换与数据离散化



Chapter 3.1

数据存在的问题

- 数据预处理是数据挖掘中的重要一环，而且必不可少。要更有效地挖掘出知识，就必须为其提供干净，准确，简洁的数据。
- 现实世界中数据常常是不完整，不一致的脏数据，无法直接进行数据挖掘，或挖掘结果差强人意。

1. 原始数据存在的问题

– 数据的不一致：各系统间的数据存在较大的不一致性

如属性重量的单位：

A数据库重量单位kg

B数据库重量单位g

1. 原始数据存在的问题

– 噪声数据：数据中存在着错误或异常（偏离期望值），如：

血压和身高为0就是明显的错误。

收集数据的时候难以得到精确的数据，主要原因：

收集数据的设备可能出现故障；

数据输入时可能出现错误；

数据传输过程中可能出现错误；

存储介质有可能出现损坏等。

1. 原始数据存在的问题

— 缺失值：由于实际系统设计时存在的缺陷以及使用过程中的一些人为因素，数据记录可能会出现数据值的丢失或不确定。

原因可能有：


- 有些属性的内容有时没有（家庭收入，参与销售事务数据中的顾客信息）；
- 有些数据当时被认为是不必要的；
- 由于误解或检测设备失灵导致相关数据没有记录下来；
- 与其它记录内容不一致而被删除；
- 忽略了历史数据或对数据的修改。

2. 数据质量要求

- 准确性：数据记录的信息是否存在异常或错误。
- 完整性：数据信息是否存在缺失。
- 一致性：指数据是否遵循了统一的规范，数据集合是否保持了统一的格式
- 时效性：某些数据是否能及时更新
- 可信性：用户信赖的数据的数量
- 可解释性：指数据自身是否易于人们理解

3. 数据预处理的主要任务

- 数据清理（清洗）：去掉数据中的噪声，纠正不一致。
- 数据集成：将多个数据源合并成一致的数据存储，构成一个完整的数据集，如数据仓库。
- 数据归约（消减）：通过聚集、删除冗余属性或聚类等方法来压缩数据。
- 数据变换（转换）：将一种格式的数据转换为另一格式的数据（如规范化）。



感谢指导！

THANKS FOR YOUR ATTENTION