



第3章 数据预处理



Chapter 3.2

数据清理

数据清理就是对数据进行重新审查和校验的过程。其目的在于纠正存在的错误，并提供数据一致性。

- 缺失值的处理；
- 噪声数据；
- 不一致数据。

1. 空缺值的处理

– 引起空缺值的原因

- 设备异常
- 与其他已有数据不一致而被删除
- 因为误解而没有被输入的数据
- 在输入时，有些数据因为得不到重视而没有被输入
- 对数据的改变没有进行日志记载

– 空缺值要经过推断而补上

✓ 如何处理空缺值?

1) 忽略元组:

- 若一条记录中有属性值被遗漏了, 则将该记录排除在数据挖掘之外
- 但是, 当某类属性的空缺值所占百分比很大时, 直接忽略元组会使挖掘性能变得非常差

2) 忽略属性列:


- 若某个属性的缺失值太多, 则在整个数据集中可以忽略该属性

3) 人工填写空缺值:


- 工作量大，可行性低

4) 使用属性的中心度量值填充空缺值:


- 如果数据的分布是正常的，就可以使用均值来填充缺失值
- 如果数据的分布是倾斜的，可以使用中位数来填充缺失值。



a) 对称数据



b) 正倾斜数据



c) 负倾斜数据

5) 使用一个全局变量填充空缺值:

- 对一个所有属性的所有缺失值都使用一个固定的值来填补（如“Not sure”或 ∞ ）。

6) 使用可能的特征值来替换空缺值（最常用）:

- 生成一个预测模型，来预测每个丢失值
- 如可以利用回归、贝叶斯计算公式或判定树归纳确定，推断出该条记录特定属性最大可能的取值

2. 噪声的处理

—噪声(noise)：被测量的变量产生的随机错误或误差

- 数据收集工具的问题
- 数据输入错误
- 数据传输错误
- 技术限制
- 命名规则的不一致

✓ 如何检测噪声数据？

-1) 基于统计的技术

- 使用距离度量值（如马氏距离）来实现。
- 给定p维数据集中的n个观察值 x_i （其中 $n \gg p$ ），用 $\bar{x}_n$ 表示样本平均向量， V_n 表示样本协方差矩阵，其中：

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)(x_i - \bar{x}_n)^T$$

- 每个多元数据点 i ($i=1, 2, \dots, n$) 的马氏距离用 M_i 表示，为：

$$M_i = \left[\sum_{i=1}^n (x_i - \bar{x}_n)^T V_n^{-1} (x_i - \bar{x}_n) \right]^{\frac{1}{2}}$$

2) 基于距离的技术

- 计算n维数据集中所有样本间的测量距离。
- 如果样本S中至少有一部分数量为p的样本到 s_i 的距离比d大，那么样本 s_i 就是数据集S中的一个噪声数据。

例：基于距离的噪声检测方法

给定一组三维样本 S , $S = \{S_1, S_2, S_3, S_4, S_5, S_6\} = \{(1, 2, 0), (3, 1, 4), (2, 1, 5), (0, 1, 6), (2, 4, 3), (4, 4, 2)\}$

求在距离阈值 d 大于等于4, 非邻点样本的阈值 p 大于等于3时的噪声数据。

首先, 求数据集的欧几里得距离 $d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$

表3.1 数据集 S 的距离表

	S_1	S_2	S_3	S_4	S_5	S_6
S_1		4.583	5.196	6.164	3.742	4.123
S_2			1.414	3.606	3.317	3.742
S_3				2.236	3.606	4.690
S_4					4.690	6.403
S_5						2.236


然后根据阈值距离 $d=4$ ，计算出每个样本 p 的值，即距离大于等于 d 的样本数量

表3.2 S中每个样本的距离大于 d 的 p 点个数

样本	p
S_1	4
S_2	1
S_3	2
S_4	3
S_5	1
S_6	3

3. 不一致数据的处理

- 数据的不一致性，就是指各类数据的矛盾性、不相容性
- 数据库系统都会有一些相应的措施来解决并保护数据库的一致性，可以使用数据库系统来保护数据的一致。



感谢指导!

THANKS FOR YOUR ATTENTION