



第3章 数据预处理

目录 CONTENTS

3.1

数据存在的问题

3.2

数据清理

3.3

数据集成

3.4

数据归约

3.5

数据变换与数据离散化



Chapter 3.3



数据集成

– 数据集成

- 把不同来源、格式、特点和性质的数据合理地集中并合并起来。
- 这些数据源可以是关系型数据库、数据立方体或一般文件。

– 它需要统一原始数据中的所有矛盾之处，如字段的

- 同名异义；
- 异名同义；
- 单位不统一；
- 字长不一致等。

— 集成过程中需要注意的问题：

- 集成的过程中涉及的实体识别问题；
- 冗余问题。

1. 集成的过程中涉及的实体识别：

- 整合不同数据源中的元数据；
- 进行实体识别：匹配来自不同数据源的现实世界的实体；
 - 如：如何确定一个数据库中的brand和另一个数据库中的product是同一实体。
 - 通常，数据库的**数据字典**和数据仓库的**元数据**，可帮助避免模式集成中的错误。

2. 冗余问题

- 同一属性在不同的数据库或同一数据库的不同数据表中会有不同的字段名；
- 一个属性可以由另外的属性导出，如：一个顾客数据表中的平均月收入属性，可以根据月收入属性计算出来。

3. 检测冗余的方法：

– 相关性分析

- 数值属性：采用相关系数和协方差进行相关性分析
- 标称属性：采用 χ^2 （卡方）检验进行相关性分析

检测冗余的方法：

- 数值属性：采用相关系数和协方差进行相关性分析

1) 相关系数：

$$r_{X,Y} = \frac{\sum_{i=1}^m (x_i - \bar{X})(y_i - \bar{Y})}{m\sigma_X\sigma_Y} = \frac{\sum_{i=1}^m (x_i y_i) - m\bar{X}\bar{Y}}{m\sigma_X\sigma_Y}$$

式中的m代表的是元组的个数， x_i 是元组i在属性X上的值， y_i 是元组i在属性Y上的值， $\bar{X}$ 表示X的均值， $\bar{Y}$ 表示Y的均值， σ_x 表示X的标准差， σ_Y 表示Y的标准差， $\sum_{i=1}^m (x_i y_i)$ 表示每个元组中X的值乘Y的值。且 $r_{X,Y}$ 的取值范围为 $-1 \leq r_{X,Y} \leq 1$ 。

检测冗余的方法:

1) 相关系数:

$$r_{X,Y} = \frac{\sum_{i=1}^m (x_i - \bar{X})(y_i - \bar{Y})}{m\sigma_X\sigma_Y} = \frac{\sum_{i=1}^m (x_i y_i) - m\bar{X}\bar{Y}}{m\sigma_X\sigma_Y}$$

- 如果 $r_{X,Y} > 0$, 则X和Y是正相关的。
- 如果 $r_{X,Y} = 0$, 则X和Y是独立的且互不相关。
- 如果 $r_{X,Y} < 0$, 则X和Y是负相关的。

— 相关系数实例

例：数值属性的相关性分析。

表3.3 体重与血压表

	1	2	3	4	5	6	7	8	9	10	11	12
体重	68	48	56	60	83	56	62	59	77	58	75	64
血压	95	98	87	96	110	155	135	128	113	168	120	115

表3.4 体重和血压的均值和标准差值

	均值	标准差
体重	63. 83	10. 14
血压	118. 33	24. 74

$$r_{X,Y} = \frac{\sum_{i=1}^m (x_i - \bar{X})(y_i - \bar{Y})}{m\sigma_X\sigma_Y} = -0.112$$

– 数值属性：采用协方差进行相关性分析

2) 协方差：设有两个属性 X 和 Y ，以及有 m 次观测值的集合 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$

$$Cov(X, Y) = E((X - \bar{X})(Y - \bar{Y})) = \frac{\sum_{i=1}^m (x_i - \bar{X})(y_i - \bar{Y})}{m} = E(XY) - E(X)E(Y)$$

其中：

$$E(X) = \bar{X} = \frac{\sum_{i=1}^m x_i}{m}$$

$$E(Y) = \bar{Y} = \frac{\sum_{i=1}^m y_i}{m}$$

$$r_{X,Y} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

– 数值属性：采用协方差进行相关性分析

协方差：

$$\text{Cov}(X, Y) = E((X - \bar{X})(Y - \bar{Y})) = \frac{\sum_{i=1}^m (x_i - \bar{X})(y_i - \bar{Y})}{m} = E(XY) - E(X)E(Y)$$

当 $\text{Cov}(X, Y) > 0$ 时，表明X与Y正相关；

当 $\text{Cov}(X, Y) < 0$ 时，表明X与Y负相关；

当 $\text{Cov}(X, Y) = 0$ 时，表明X与Y不相关。

– 数值属性：采用协方差进行相关性分析

假设属性 X 和 Y 是相互独立的，有

$$E(X \cdot Y) = E(X) \cdot E(Y)$$

协方差的公式是

$$\text{Cov}(X, Y) = E(X \cdot Y) - \bar{X}\bar{Y} = E(X) \cdot E(Y) - \bar{X}\bar{Y} = 0。$$

但是，它的逆命题是不成立的。

– 协方差实例

例：数值属性的协方差计算。

求上例中血压是否会随着体重一起变化。

$$E(X) = \frac{68 + 48 + 56 + 60 + 83 + 56 + 62 + 59 + 77 + 58 + 75 + 64}{12} = 63.83$$

$$E(Y) = \frac{95 + 98 + 87 + 96 + 110 + 155 + 135 + 128 + 113 + 168 + 120 + 115}{12} = 118.33$$

$$Cov(X, Y) = r_{X,Y} \cdot \sigma_X \cdot \sigma_Y = -0.112 \times 10.14 \times 24.74 = -28.10$$

– 标称属性：使用卡方检验进行相关性分析

表 列联表

$Y \backslash X$	x_1	x_2	...	x_i	...	x_n	sum
y_1	O_{11}	O_{12}	...	O_{1i}	...	O_{1n}	$O_{1.}$
y_2	O_{21}	O_{22}	...	O_{2i}	...	O_{2n}	$O_{2.}$
...	...	...	...	...	...	...	...
y_j	O_{j1}	O_{j2}	...	O_{ji}	...	O_{jn}	$O_{j.}$
...	...	...	...	...	...	...	...
y_r	O_{r1}	O_{r2}	...	O_{ri}	...	O_{rn}	$O_{r.}$
sum	$O_{.1}$	$O_{.2}$	...	$O_{.i}$	...	$O_{.n}$	m

– 标称属性：使用卡方检验进行相关性分析

独立性检验的步骤如下：

- (1) 统计假设： H_0 ：属性X和属性Y之间是独立的
- (2) 期望频数的计算，计算公式如式所示。

$$e_{ij} = \frac{(o_{i.} \times O_{.j})}{m}$$

- (3) 自由度的确定

$$df = (r - 1) \times (n - 1)$$

– 标称属性：使用卡方检验进行相关性分析

(4) *Pearson* χ^2 统计量的计算：

$$\chi^2 = \sum_{i=1}^n \sum_{j=1}^r \frac{(o_{ij} - e_{ij})^2}{e_{ij}}$$

$$e_{ij} = \frac{\text{count}(X = x_i) \times \text{count}(Y = y_j)}{m}$$

– 标称属性：使用卡方检验进行相关性分析

(5) 统计推断

$\chi^2 > \text{临界值}$ （具有自由度df和显著水平） α ：拒绝假设 H_0

$\chi^2 < \text{临界值}$ （具有自由度df和显著水平） α ：接受假设 H_0

— 卡方检验实例：二分类情况

例：对从事两种工种的某一年龄段男性患某种疾病的情况进行调查，如下表。分析某一年龄段男性患某种疾病与从事工种是否相关。

表 四方格列联表

患病情况 从事工种	患病	不患病	合计
工种1	386	895	1281
工种2	65	322	387
合计	451	1217	1668

— 卡方检验实例：二分类情况

(1) 统计假设：

H_0 ：某一年龄段男性患高血压病与从事工农业不相关

(2) 期望频数的计算。

表 四方格列联表（期望频数）

患病情况 从业情况	患病	不患病	合计
工业	386 (346.36)	895 (934.64)	1281
农业	65 (104.64)	322 (282.36)	387
合计	451	1217	1668

— 卡方检验实例：二分类情况

(3) 自由度的确定： $df = (2-1) * (2-1) = 1$

(4) 卡方统计量的计算

表 四方格列联表（期望频数）

患病情况 从业情况	患病	不患病	合计
工业	386 (346.36)	895 (934.64)	1281
农业	65 (104.64)	322 (282.36)	387
合计	451	1217	1668

$$\chi^2 = \frac{(386-346.36)^2}{346.36} + \frac{(895-934.64)^2}{934.64} + \frac{(65-104.64)^2}{104.64} + \frac{(322-282.36)^2}{282.36} = 25.204$$

— 卡方检验实例：二分类情况

(5) 统计判断

表 卡方检验临界值表 (部分)

显著水平 α 自由度	0.99	0.98	0.95	0.90	0.50	0.10	0.05	0.02	0.01	0.005
1	0.000	0.001	0.004	0.016	0.045	2.71	3.84	5.41	6.64	10.83
2	0.020	0.040	0.103	0.211	1.36	4.61	5.99	7.82	9.21	13.82
3	0.115	0.185	0.352	0.584	2.366	6.25	7.82	9.84	11.34	16.27


— 卡方检验实例：二分类情况

两个独立样本比较可以分为以下3种情况：

- 1.所有的期望频数 $e_{ij} \geq 5$ 并且总样本量 $m \geq 40$ ，用Pearson卡方进行检验。
- 2.如果期望频数 $e_{ij} < 5$ 但 $e_{ij} \geq 1$ ，并且 $m \geq 40$ ，用连续性校正的卡方进行检验。

$$\chi^2 = \sum_{i=1}^n \sum_{j=1}^r \frac{(|o_{ij} - e_{ij}| - 0.5)^2}{e_{ij}}$$

- 3.如果有期望频数 $e_{ij} < 1$ 或 $m < 40$ ，则用精确概率检验。



感谢指导!

THANKS FOR YOUR ATTENTION