



第3章 数据预处理

目录 CONTENTS

3.1

数据存在的问题

3.2

数据清理

3.3

数据集成

3.4

数据归约

3.5

数据变换与数据离散化



Chapter 3.4

数据归约

- 对大规模数据库内容进行复杂的数据分析常需要消耗大量的时间，使得这样的分析变得不现实和不可行；
- 数据归约（data reduction）：数据消减或约简，是在不影响最终挖掘结果的前提下，缩小所挖掘数据的规模；
- 数据归约技术可以用来得到数据集的归约表示，它小得多，但仍接近保持原数据的完整性；
- 对归约后的数据集进行挖掘可提高挖掘的效率，并产生相同（或几乎相同）的结果。

— 数据归约的标准：

- 用于数据归约的时间不应当超过或“抵消”在归约后的数据集上挖掘节省的时间。
- 归约得到的数据比原数据小得多，但可以产生相同或几乎相同的分析结果。

— 数量归约：直方图

- 直方图（Histogram）是一种常见的数据归约的形式。属性X的直方图将X的数据分布划分为不相交的子集或桶。通常情况下，子集或桶表示给定属性的一个连续区间。单值桶表示每个桶只代表单个属性值/频率对（单值桶对于存放那些高频率的离群点，非常有效）
- 划分桶和属性值的方法有两种：
 - ①等宽：在等宽直方图中，每个桶的宽度区间是一致的。
 - ②等频（或等深）：在等频直方图中，每个桶的频率粗略地计为常数，即每个桶大致包含相同个数的邻近数据样本。

例：用直方图表示数据

已知某人在不同时刻下所量血压值为：95，98，87，96，110，155，135，128，113，168，120，115，110，155，135，128，113，158，87，96，110，98，87，94，80，93，89，95，99，101，111，123，128，113，158，128，113，168，87，96，110。

使用等宽直方图表示数据，如图所示。由于需要继续压缩数据，所以一般都是使用桶来表示某个属性的一个连续值域。

等宽直方图





图3-2 等宽直方图

— 数量归约：数据立方体

- 数据立方体是一类多维矩阵，可以使用户从多个角度探索和分析数据集，它的数据是已经处理过的，并且聚合成了立方形式。
- 数据立方体的基本概念。
 - ①方体：不同层创建的数据立方体。
 - ②基本方体：最低抽象层创建的立方体。
 - ③顶方体：最高层抽象的立方体。
 - ④方体的格：每一个数据立方体。

数量归约：数据立方体

北京地区1月份电视的销售量



北京地区四个月电视的销售总量

北京地区四个月三种商品的销售总量


三个城市四个月电视的销售总量

三个城市四个月三种商品的销售总量

北京地区1月份三种商品的销售总额

三个城市1月份三种商品的销售总额

—数量归约：数据立方体——方体的格



— 数据归约—属性子集选择：检测并删除不相关、弱相关或冗余的属性。

属性子集选择的基本启发式方法包括逐步向前选择、逐步向后删除、逐步向前选择和逐步向后删除的组合以及决策树归纳，表3.7给出了属性子集选择方法。

表3.7 属性子集选择方法

向前选择	向后删除	决策树归纳
初始属性集： $\{X_1, X_2, X_3, X_4, X_5, X_6\}$	初始属性集： $\{X_1, X_2, X_3, X_4, X_5, X_6\}$	初始属性集： $\{X_1, X_2, X_3, X_4, X_5, X_6\}$
初始化归约集： $\{\}$ $\Rightarrow \{X_1\}$ $\Rightarrow \{X_1, X_4\}$ $\Rightarrow \{X_1, X_4, X_6\}$	$\Rightarrow \{X_1, X_2, X_3, X_4, X_5, X_6\}$ $\Rightarrow \{X_1, X_3, X_4, X_5, X_6\}$ $\Rightarrow \{X_1, X_4, X_5, X_6\}$ $\Rightarrow \{X_1, X_4, X_6\}$	
归约后的属性集： $\{X_1, X_4, X_6\}$	归约后的属性集： $\{X_1, X_4, X_6\}$	归约后的属性集： $\{X_1, X_4, X_6\}$


— 数据归约—抽样

- 允许用数据的较小随机样本（子集）表示大的数据集。
- 取样方法：
 - 不放回简单随机取样（Simple Random Sampling Without Replacement, SRSWOR）
 - 放回简单随机取样（Simple Random Sampling With Replacement, SRSWR）
 - 聚类取样（Clustered Sampling）
 - 分层取样（Stratified Sampling）

— 数据归约—无放回简单随机取样 (SRSWOR) & 放回简单随机取样 (SRSWR)

- 假定大型数据集D包含N个元组
- 无放回的简单随机抽样方法，从N个元组中随机（每一数据行被选中的概率为 $1/N$ ）抽取出n个元组，以构成抽样数据子集。
- 有放回的简单随机抽样方法，与无放回简单随机抽样方法类似，也是从N个元组中每次抽取一个元组，但是抽中的元组接着放回原来的数据集D中，以构成抽样数据子集。这种方法可能会产生相同的元组。

- 数据归约—无放回简单随机取样 (SRSWOR) & 放回简单随机取样 (SRSWR)





— 数量规约-聚类采样：

首先将大数据集 D 划分为 M 个互不相交的聚类，然后再从 M 个类中的数据对象分别进行随机抽取，可最终获得聚类采样的数据子集。


原始数据

聚类样本



— 数量规约-分层取样：

- 首先将大数据集 D 划分为互不相交的层，然后对每一层简单随机选样得到 D 的分层选样。
- 如，根据顾客的年龄组进行分层，然后再在每个年龄组中进行随机选样，从而确保了最终获得分层采样数据子集中的年龄分布具有代表性。



感谢指导！

THANKS FOR YOUR ATTENTION