



Chapter 6.1

频繁模式概述

1. 购物车实例——啤酒与尿布

在美国，著名的沃尔玛超市发现**啤酒与尿布**总是共同出现在购物车中，于是沃尔玛超市经过分析发现许多美国年轻的父亲下班之后经常要去购买婴儿的尿布，而在购买尿布的同时，他们往往会顺手购买一些啤酒；因此沃尔玛超市将啤酒与尿布放在相近的位置，方便顾客购买，并明显提高了销售额。

购物车分析

频繁模式是指频繁出现在数据集中的模式，这些模式包括项集、子序列和子结构等。

研究频繁模式的目的是得到关联规则和其他的联系，并在实际中应用这些规则和联系。

面包和牛奶共同出现在购物车中，这代表了什么？

购买了油、牛奶、面包、香蕉、洗衣液、还应该有哪些商品？

买了这么多的鱼子酱，是因为促销吗？

购买了油、牛奶、面包、香蕉、葡萄、洗衣液，还应该有哪些商品？



上图能挖掘出哪些有趣的模式？

例6.1 购物车分析

表6-1 某商店的事务数据

TID	Items
1	牛奶, 面包, 麦片
2	牛奶, 面包, 麦片, 鸡蛋
3	牛奶, 面包, 黄油, 麦片
4	糖, 鸡蛋
5	黄油, 麦片
6	糖, 鸡蛋

2. 相关概念

表6-1 某商店的事务数据

TID	Items
1	牛奶, 面包, 麦片
2	牛奶, 面包, 麦片, 鸡蛋
3	牛奶, 面包, 黄油, 麦片
4	糖, 鸡蛋
5	黄油, 麦片
6	糖, 鸡蛋

– 项集

包含0个或者多个项的集合

– 支持度

绝对支持度：项集的出现频度，即包含项集的事务数。

相对支持度：项集出现的百分比

– 频繁项集

事务中同时包含集合A和集合B的事务数
与包含集合A的事务数的百分比

– 关联规则

设 $I = \{i_1, i_2, i_3, \dots, i_n\}$ 是事务数据中所有项的集合,
 $T = \{t_1, t_2, t_3, \dots, t_n\}$ 是所有事务的集合, 其中每个事务 t_i 都有一个独一无二的标识符 TID 。

关联规则是形如 $A \Rightarrow B$ 的蕴含式, 其中 A 称为规则前件, B 称为规则后件, 并且 A, B 满足: A, B 是 I 的真子集, 并且 A 和 B 的交集为空集。

关联规则的支持度是指事务中同时包含集合 A 和集合 B 的百分比。

$$support(A \Rightarrow B) = P(A \cup B)$$

– 置信度

置信度是指事务中同时包含集合 A 与 B 的事务数与包含集合 A 的事务数的百分比。

$$confidence(A \Rightarrow B) = P(B|A)$$

表6-1 某商店的事务数据

TID	Items
1	牛奶, 面包, 麦片
2	牛奶, 面包, 麦片, 鸡蛋
3	牛奶, 面包, 黄油, 麦片
4	糖, 鸡蛋
5	黄油, 麦片
6	糖, 鸡蛋

— 强关联规则

同时满足最小支持度和最小置信度阈值要求的所有关联规则被称为**强关联规则**。

例6.6 强关联规则

假设最小置信度阈值为30%，最小置信度阈值为70%，而关联规则：购买面包 $\Rightarrow$ 购买牛奶
[支持度=50%，置信度=100%]的支持度和置信度都满足条件，则该规则为强关联规则。

3. 先验性质

— 关联规则挖掘的任务

- ①根据最小支持度阈值，找出数据集中所有的频繁项集；
- ②挖掘出频繁项集中满足最小支持度和最小置信度阈值要求的规则，得到强关联规则；
- ③对产生的强关联规则进行剪枝，找出有用的关联规则。

— 先验性质

如果一个项集是频繁的，那么它的所有非空子集也是频繁的。