



Chapter 6.2

Apriori算法

关联规则挖掘的步骤

1. 找出所有频繁项集，即大于或等于最小支持度阈值的项集
2. 由频繁项集产生强关联规则，这些规则必须大于或等于最小支持度阈值和最小置信度阈值。

Apriori算法

是布尔关联规则挖掘频繁项集的原创性算法，算法使用频繁项集性质的先验知识。

- Apriori算法使用一种称为**逐层搜索的迭代方法**，其中 k 项集用于搜索 $(k+1)$ 项集。
- 首先，通过扫描数据库，累计每个项的个数，并收集满足最小支持度的项，找出频繁1项集的集合。该集合记为 L_1 ，使用 L_1 找出频繁2项集的集合 L_2 ，使用 L_2 找出 L_3 ，如此下去，直到不能再找到频繁 k 项集。找出每一个 L_k 需要一次数据库的完整扫描。

Apriori算法的实现步骤如下:

— 连接

- 算法初始设置 $k=1$ ，使用连接运算从数据库中找到所有的 k 项候选集的集合 C_k ，然后 k 增加1，直到 k 等于频繁项集的极大长度或频繁项集为空。构造 k 项候选集的集合 C_k (k 不等于1) 时，每次连接步都使用前一次迭代中的所有频繁 $k-1$ 项集的集合 L_{k-1} 的相互连接来构造频繁 k 项候选集的集合 $C_k = L_{k-1} \bowtie L_{k-1}$ ，其中 L_{k-1} 的元素是可连接的，如果它们前 $k-2$ 个项是相同的，即两个可连接的元素只有最后一项不同，这样可简单地确保不产生重复。

Apriori算法的实现步骤如下:

— 剪枝

- 按照先验原理对得到的k项候选集的集合 C_k 进行剪枝, 以减小因 C_k 较大而产生较大的计算量。先验性质指出如果某一k-1项集的支持度小于最小支持度阈值, 那么它的所有真超项集的支持度都小于最小支持度阈值, 所以该k-1项集和它的所有真超项集都不是频繁项集, 从而可以在 C_k 中剪掉该k-1项集的真超k项集, 在以后的迭代步骤中不予考虑。然后可以根据最小支持度阈值, 在剪枝后的k项候选集的集合 C_k 中剪掉支持度小于最小支持度阈值的k项集, 生成频繁k项集的集合 L_k 。

Apriori算法如下:

Apriori算法如下:

输入: 项集 I , 事务数据集 D , 最小支持度计数阈值 Min_sup

输出: D 中的所有频繁项集的集合 L 。

Apriori算法:

(1)求频繁1项集 L_1

首先通过扫描事务数据集 D , 找出所有1项集并计算其支持度, 作为候选1项集 C_1 ,

然后从 C_1 中删除低于最小支持度阈值 Min_sup 的项集, 得到所有频繁1项集的集合 L_1 ,

(2) For $k=2,3,4, \dots$

(3) 连接: 将 L_{k-1} 进行自身连接生成候选 k 项集的集合 C_k , 连接方法如下: 对于任意 $p, q \in L_{k-1}$, 若按字典序有 $p = \{p_1, p_2, \dots, p_{k-2}, p_{k-1}\}$, $q = \{p_1, p_2, \dots, p_{k-2}, q_{k-1}\}$, 且满足 $p_{k-1} < q_{k-1}$, 则把 p 和 q 连接成 k 项集 $\{p_1, p_2, \dots, p_{k-2}, p_{k-1}, q_{k-1}\}$ 作为候选 k 项集 C_k 中的元素。

Apriori算法如下:

- (4) 剪枝: 删除 C_k 中的非频繁k项集, 即当 C_k 中一个候选k项集的某个k-1项子集不是 L_{k-1} 中的元素时, 则将它从 C_k 中删除。
- (5) 计算支持数: 通过扫描事务数据集D, 计算 C_k 中每个k项集的支持数。
- (6) 求 L_k : 删除 C_k 中低于最小支持度阈值Min_sup的k项集, 得到所有频繁k项集的集合 L_k 。
- (7) 若 $L_k = \emptyset$, 则转第(9)步
- (8) END FOR
- (9) 另 $L = L_1 \cup L_2 \cup \dots \cup L_k$, 并输出L。

测试数据集



TID	Items
1	面包、可乐、麦片
2	牛奶、可乐
3	牛奶、面包、麦片
4	牛奶、可乐
5	面包、鸡蛋、麦片
6	牛奶、面包、可乐
7	牛奶、面包、鸡蛋、麦片
8	牛奶、面包、可乐
9	面包、可乐

例6.7 Apriori算法

假设使用表中的事务数据，该数据库具有9个事务，设最小支持度为2，试使用Apriori算法挖掘表6-3的事务数据中的频繁项集。

➡ 6.2 Apriori算法

19



$L = \{\{\text{牛奶}\}: 6, \{\text{面包}\}: 7, \{\text{可乐}\}: 6, \{\text{鸡蛋}\}: 2, \{\text{麦片}\}: 4, \{\text{牛奶, 面包}\}: 4, \{\text{牛奶, 可乐}\}: 4, \{\text{牛奶, 麦片}\}: 2, \{\text{面包, 可乐}\}: 4, \{\text{面包, 鸡蛋}\}: 2, \{\text{面包, 麦片}\}: 4, \{\text{鸡蛋, 麦片}\}: 2, \{\text{牛奶, 面包, 可乐}\}: 2, \{\text{牛奶, 面包, 麦片}\}: 2, \{\text{面包, 鸡蛋, 麦片}\}: 2\}$

关联规则的生成过程包括以下步骤：

关联规则的生成过程包括两个步骤：

- ①对于 L 中的每个频繁项集 X ，生成 X 所有的非空真子集 Y ；
- ②对于 X 中的每一个非空真子集 Y ，构造关联规则 $Y \Rightarrow (X - Y)$ 。

构造出关联规则后，计算每一个关联规则的置信度，如果大于最小置信度阈值，则该规则为强关联规则。

TID	Items
1	面包、可乐、麦片
2	牛奶、可乐
3	牛奶、面包、麦片
4	牛奶、可乐
5	面包、鸡蛋、麦片
6	牛奶、面包、可乐
7	牛奶、面包、鸡蛋、麦片
8	牛奶、面包、可乐
9	面包、可乐

对于上例6中L中的频繁3项集{牛奶, 面包, 麦片}, 可以推导出非空子集:

{{牛奶}, {面包}, {麦片}, {牛奶, 面包}, {牛奶, 麦片}, {面包, 麦片}}。

可以构造的关联规则及置信度如下:

{牛奶} $\Rightarrow$ {面包, 麦片}, 置信度=2/6=33%

{面包} $\Rightarrow$ {牛奶, 麦片}, 置信度=2/7=29%

{麦片} $\Rightarrow$ {牛奶, 面包}, 置信度=2/4=50%

{牛奶, 面包} $\Rightarrow$ {麦片}, 置信度=2/4=50%

{牛奶, 麦片} $\Rightarrow$ {面包}, 置信度=2/2=100%

{面包, 麦片} $\Rightarrow$ {牛奶}, 置信度=2/4=50%

令最小置信度为70%，则得到的强关联规则有:

{牛奶, 麦片} $\Rightarrow$ {面包}, 置信度=2/2=100%

可以通过枚举频繁项集生成所有的关联规则，并通过计算关联规则的置信度来判断该规则是否为强关联规则。但当一个频繁项集包含的项很多时，就会生成大量的候选关联规则，一个频繁项集 X 能够生成 $2^{|X|}-2$ 个（即除去空集及自身之外的子集）候选关联规则。

可以逐层生成关联规则，并利用如下关联规则的性质进行剪枝，以减少关联规则生成的计算工作量。

关联规则性质：设 X 为频繁项集， $\emptyset \neq Y \subset X$ 且 $\emptyset \neq Y' \subset Y$ 。若 $Y \Rightarrow (X - Y)$ 不是强关联规则，则 $Y' \Rightarrow (X - Y')$ 也不是强关联规则。

首先产生后件只包含一个项的关联规则，然后两两合并关联规则的后件，生成后件包含两个项的候选关联规则，从这些候选关联规则中再找出强关联规则，以此类推。

TID	Items
1	面包、可乐、麦片
2	牛奶、可乐
3	牛奶、面包、麦片
4	牛奶、可乐
5	面包、鸡蛋、麦片
6	牛奶、面包、可乐
7	牛奶、面包、鸡蛋、麦片
8	牛奶、面包、可乐
9	面包、可乐

对于上例6中L中的频繁3项集{牛奶, 面包, 麦片}, 可以推导出非空子集:

{{牛奶}, {面包}, {麦片}, {牛奶, 面包}, {牛奶, 麦片}, {面包, 麦片}}。

可以构造的后件只包含一个项的关联规则及置信度如下:

{牛奶, 面包} $\Rightarrow$ {麦片}, 置信度 = $2/4 = 50\%$

{牛奶, 麦片} $\Rightarrow$ {面包}, 置信度 = $2/2 = 100\%$

{面包, 麦片} $\Rightarrow$ {牛奶}, 置信度 = $2/4 = 50\%$

令最小置信度为70%，则得到的强关联规则有:

{牛奶, 麦片} $\Rightarrow$ {面包}, 置信度 = $2/2 = 100\%$

生成后件包含两个项的关联规则及置信度如下:

{麦片} $\Rightarrow$ {牛奶, 面包}, 置信度 = $2/4 = 50\%$

关联规则挖掘中重要的基础理论：

1. 频繁项集的性质：

- ①如果 X 是频繁项集，则它的任何非空子集 X' 也是频繁项集。即频繁项集的子集也是频繁项集。
- ②如果 X 是非频繁项集，则它的所有真超级都是非频繁项集。即非频繁项集的超集也是非频繁项集。

关联规则挖掘中重要的基础理论：

2. 关联规则的性质：

- ① 设 X 为频繁项集， $\emptyset \neq Y \subset X$ 且 $\emptyset \neq Y' \subset Y$ 。若 $Y' \Rightarrow (X - Y')$ 为强关联规则，则 $Y \Rightarrow (X - Y)$ 也是强关联规则。
- ② 设 X 为频繁项集， $\emptyset \neq Y \subset X$ 且 $\emptyset \neq Y' \subset Y$ 。若 $Y \Rightarrow (X - Y)$ 不是强关联规则，则 $Y' \Rightarrow (X - Y')$ 也不是强关联规则。