



Chapter 6.4

压缩频繁项集

- 在实际应用中，当最小支持度阈值较低或者数据规模较大时，使用频繁模式挖掘事务数据可能产生过多的频繁项集；
- 而闭频繁模式、极大模式等模式可以显著减少频繁模式挖掘所产生的频繁项集数量。

1. 挖掘闭模式

如果 $X \in Y$ ，且 Y 中至少有一项不在 X 中，那么 Y 是 X 的真超项集。如果在数据集中不存在频繁项集 X 的**真超项集** Y ，使得 X 、 Y 的支持度相等，那么称项集 X 是这个数据集的**闭频繁项集**。

2. 剪枝的策略

– 项合并

- 如果包含频繁项集 X 的每个事务都包含项集 Y ，但不包含 Y 的任何真超集，则 $X \cup Y$ 形成一个闭频繁项集，并且不必搜索包含 X 但不包含 Y 的任何项集。

– 子项集剪枝

- 如果频繁项集 X 是一个已经发现的闭频繁项集 Y 的真子集，并且两者的支持度计数相等，则 X 和 Y 的所有后代都不可能是闭频繁项集，因此可以剪枝。


测试数据集

表6-1 项集事务

TID	Items
1	abc
2	abcd
3	ace
4	acde
5	de

测试数据集

最小支持度为2，可以得到 $\{d\}$ 、 $\{e\}$ 、 $\{ac\}$ 、 $\{de\}$ 、 $\{abc\}$ 、 $\{acd\}$ 、 $\{ace\}$ 这些频繁项集的支持度都大于等于2，并且他们都不存在等于他们支持度的真超集，所以他们是闭频繁项集。



3. 极大频繁项集:

如果在数据集中不存在频繁项集 X 的真超项集 Y , 使得 X 属于 Y 并且 Y 也是频繁项集, 那么称项集 X 是这个数据集的极大频繁项集。

可以推导出极大频繁项集是闭频繁项集, 而闭频繁项集不一定是极大频繁项集。

假设最小支持度为2，从图中可知闭频繁项集 $\{\{d\}, \{e\}, \{ac\}, \{de\}, \{abc\}, \{acd\}, \{ace\}\}$ 根据定义 $\{\{de\}, \{abc\}, \{acd\}, \{ace\}\}$ 则是极大频繁项集。

