



Chapter 6.5

关联模式评估

1. 支持度-置信度框架

- 强关联规则（支持度-置信度框架）不一定是有趣的
- 测试数据集
- 最小支持度阈值为0.3，最小置信度阈值为0.6。

表6-5 1000个人的手机偏爱

	买苹果手机	不买苹果手机	行和
买小米手机	400	350	750
不买小米手机	200	50	250
列和	600	400	1000

2. 相关性分析

1. 提升度

- 令 A 和 B 表示不同的项集， $P(*)$ 表示项集 $*$ 在总体数据集中的出现概率。根据统计学定义，如果项集 A 和项集 B 的 $P(A \cup B) = P(A)P(B)$ ，那么项集 A 和项集 B 是相互独立的，否则两者是相互依赖的。
- 项集 A 和项集 B 的提升度定义如式(6-3)所示。

$$\text{lift}(A, B) = \frac{P(A \cup B)}{P(A)P(B)}$$

如果 A 和 B 的提升度的值等于 1，说明 A 和 B 相互独立；若是 A 和 B 的提升度的值大于 1，说明 A 和 B 正相关；如果 A 和 B 的提升度的值小于 1，说明 A 和 B 负相关。

$$\text{Lift}(\{\text{苹果手机}\}, \{\text{小米手机}\}) = 0.4 / (0.75 * 0.6) = 0.89$$

— 相关性分析

2. 杠杆度

杠杆度和提升度的含义相近，其定义如式（6-4）所示。

$$\text{leverage}(A, B) = P(A \cup B) - P(A)P(B) \quad (6-4)$$

如果 A 和 B 的杠杆度的值等于0，则说明 A 和 B 相互独立；

如果 A 和 B 的杠杆度的值大于0，说明 A 和 B 正相关，并且杠杆度越大，说明 A 和 B 的关系越密切；

如果 A 和 B 的杠杆度的值小于0，说明 A 和 B 负相关。

{苹果手机}、{小米手机} 的杠杆度为

$$\text{leverage}(\{\text{苹果手机}\}, \{\text{小米手机}\}) = 0.4 - 0.6 \times 0.75 = -0.05$$

苹果手机和小米手机是负相关的。

— 相关性分析

3. 皮尔森相关系数

皮尔森相关系数能够反映两个变量的相似程度，皮尔森相关系数值越大表明两个变量的相关性越强。对于二元变量，皮尔森相关系数定义如式(6-4)所示。

$$\rho(A, B) = \frac{P(A \cup B)P(\bar{A} \cup \bar{B}) - P(\bar{A} \cup B)P(A \cup \bar{B})}{\sqrt{P(A)P(\bar{A})P(B)P(\bar{B})}}$$

{苹果手机}和{小米手机}的皮尔森相关系数为

$$\rho(\{\text{苹果手机}\}, \{\text{小米手机}\}) = \frac{(0.4 * 0.05 - 0.35 * 0.2)}{\sqrt{0.6 * 0.4 * 0.75 * 0.25}} = -0.2357$$

说明两者一定程度负相关。

— 相关性分析

3.IS度量

IS度量通常用于处理非对称二元变量，IS度量定义如式(6-5)所示。

$$IS(A, B) = \frac{P(A \cup B)}{\sqrt{P(A)P(B)}}$$

IS度量的数值越大则说明A和B之间的关联越强。

{苹果手机}和{小米手机}的IS度量为

$$IS(\{\text{苹果手机}\}, \{\text{小米手机}\}) = \frac{0.4}{\sqrt{0.6 * 0.75}} = 0.5963$$

说明A和B关联一般。

— 相关性分析

4. 确信度

确信度能够度量一个规则的强度，同时衡量A和B之间的独立性。确信度定义如式(6-6)所示。

$$Conviction(A, B) = \frac{P(A)P(\bar{B})}{\sqrt{P(A \cup \bar{B})}}$$

确信度越大，A和B关系越紧密。

{苹果手机}和{小米手机}的确信度为

$$Conviction(\{\text{苹果手机}\}, \{\text{小米手机}\}) = \frac{0.6 * 0.25}{\sqrt{0.2}} = 0.33541$$

，说明苹果手机和小米手机的关系不紧密。

3. 模式评估度量

不包含任何考察项集的事务被称作零事务。提升度、皮尔森相关系数和卡方系数等度量在很大程度上受零事务的影响，因此它们识别关联模式关联关系的能力较差。

1. 全置信度

全置信度反映了规则 $A \Rightarrow B$ 和规则 $B \Rightarrow A$ 的最小置信度。全置信度定义如式(6-7)所示。

- $$all_conf(A, B) = \frac{P(A \cup B)}{\max\{P(A), P(B)\}} = \min\{P(A|B), P(B|A)\} \quad (6-7)$$
- 对于项集 A 和 B ，全置信度越大，说明规则 $A \Rightarrow B$ 和规则 $B \Rightarrow A$ 的最小置信度越大，那么 A 和 B 关系越紧密，反之 A 和 B 关系越疏远。

{苹果手机}和{小米手机}的全置信度为

$$all_conf(\{\text{苹果手机}\}, \{\text{小米手机}\}) = \frac{0.4}{\max\{0.6, 0.75\}} = 0.5333$$

说明苹果手机和小米手机的关系一般。

3. 模式评估度量

2. 极大置信度

极大置信度则反映了规则 $A \Rightarrow B$ 和规则 $B \Rightarrow A$ 的最大置信度。极大置信度定义如式 (6-8) 所示。

$$\max_conf(A, B) = \max\{P(A|B), P(B|A)\} \quad (6-8)$$

对于项集 A 和 B ，极大置信度越大， A 和 B 关系越紧密。

{苹果手机} 和 {小米手机} 的极大置信度为

$$\max_conf(\{\text{苹果手机}\}, \{\text{小米手机}\}) = \max\left(\frac{0.4}{0.6}, \frac{0.4}{0.75}\right) = 0.667$$

说明两者可能关系一般。

3. 模式评估度量

Kulczynski度量

Kulczynski度量表示在项集 A 存在的情况下项集 B 也存在的条件概率和在项集 B 存在的情况下项集 A 也存在的条件概率之和的平均值。Kulczynski度量定义如式(6-9)所示。


$$Kulc(A, B) = \frac{1}{2} (P(A|B) + P(B|A)) \quad (6-9)$$

对于项集 A 和 B ，Kulczynski度量越大，说明平均可信程度越大，那么 A 和 B 关系越紧密。

{苹果手机}和{小米手机}的**.(库尔钦斯基)**Kulczynski度量为

$$Kulc(\{苹果手机\}, \{小米手机\}) = \frac{1}{2} \left(\frac{0.4}{0.6} + \frac{0.4}{0.75} \right) = 0.6$$

说明两者关系一般。



感谢指导!

THANKS FOR YOUR ATTENTION