



第7章 分类

目录 CONTENTS

7.1

分类概述

7.2

决策树

7.3

朴素贝叶斯分类

7.4

惰性学习法

7.5

神经网络

7.6

分类模型的评估



Chapter 7.1

分类概述

什么是分类？

- 分类就是根据以往的数据和结果对另一部分数据进行结果的预测。
- 模型的学习在被告知每个训练样本属于哪个类的“指导”下进行新数据使用训练数据集中得到的规则进行分类

分类的基本过程：

学习阶段：建立一个分类模型，描述预定数据类或概念集。评估模型的预测准确率。如果准确率可以接受，那么使用该模型来分类标签为未知的样本。

分类阶段：即使用分类模型，对将来的或未知的对象进行分类。

数据集：训练集、测试集、预测数据集

分类与预测

- 不同点

- 分类是预测类对象的分类标号（或离散值），根据训练数据集和类标号属性，构建模型来分类现有数据，并用来分类新数据。
- 预测是建立连续函数值模型评估无标号样本类，或评估给定样本可能具有的属性值或值区间，即用来估计连续值或量化属性值，比如预测空缺值。

- 相同点

- 分类和预测的共同点是两者都需要构建模型，都用模型来估计未知值。预测中主要的估计方法是回归分析。

分类的相关知识：

- 1、信息熵

信息熵用来衡量事件的不确定性的大小，计算公式如下：

$$Infor(x) = - p(x) \times \log_2 p(x)$$

信息熵具有可加性，即多个期望信息，计算公式如下：

$$Infor(X) = - \sum_{i=1}^m p(x_i) \times \log_2 p(x_i)$$

分类的相关知识：

- 2、信息增益

信息增益表示某一特征的信息对类标签的不确定性减少的程度。

$$g(D|A) = Infor(D) - Infor(D|A)$$

其中 $Infor(D|A)$ 是在特征 A 给定条件下对数据集 D 进行划分所需要的期望信息，它的值越小表示分区的纯度越高，计算公式如式(7-4)所示。

$$Infor(D|A) = \sum_{j=1}^n \frac{|D_j|}{|D|} \times Info(D_j) \quad (7-4)$$

其中 n 是数据分区数， $|D_j|$ 表示第 j 个数据分区的长度， $\frac{|D_j|}{|D|}$ 表示第 j 个数据分区的权重。

➡ 7.1 分类概述

- 例7.1 信息增益的计算
- 表7-1是带有标记类的训练集 D ，训练集的列是一些特征，表中最后一列的类标号为是否提供贷款，有两个不同的取值，计算按照每个特征进行划分的信息增益。

表7-1 贷款申请的训练集

ID	学历	婚否	是否有车	收入水平	类别
1	专科	否	否	中	否
2	专科	否	否	高	否
3	专科	是	否	高	是
4	专科	是	是	中	是
5	专科	否	否	中	否
6	本科	否	否	中	否
7	本科	否	否	高	否
8	本科	是	是	高	是
9	本科	否	是	很高	是
10	本科	否	是	很高	是
11	研究生	否	是	很高	是
12	研究生	否	是	高	是
13	研究生	是	否	高	是
14	研究生	是	否	很高	是
15	研究生	否	否	中	否

①根据公式计算信息熵 $Inf or(D)$ 。

$$Inf or(D) = -\frac{9}{15} \times \log_2 \frac{9}{15} - \frac{6}{15} \times \log_2 \frac{6}{15} = 0.971$$

②计算按照每个特征进行划分的期望信息， A 代表特征“学历”， B 代表特征“婚否”， C 代表特征“是否有车”， E 代表特征“收入水平”。

$$\begin{aligned} Inf or(D|A) &= \frac{5}{15} \times \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{5}{15} \times \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) \\ &\quad + \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) = 0.888 \end{aligned}$$

$$Inf or(D|B) = Inf or(D|B) = \frac{10}{15} \times \left(-\frac{6}{10} \log_2 \frac{6}{10} - \frac{4}{10} \log_2 \frac{4}{10} \right) + \frac{5}{15} \times \left(-\frac{5}{5} \log_2 \frac{5}{5} \right) = 0.647$$

$$Inf or(D|C) = \frac{9}{15} \times \left(-\frac{6}{9} \log_2 \frac{6}{9} - \frac{3}{9} \log_2 \frac{3}{9} \right) + \frac{6}{15} \times \left(-\frac{6}{6} \log_2 \frac{6}{6} \right) = 0.951$$

$$Inf or(D|E)$$

$$= \frac{5}{15} \times \left(-\frac{4}{5} \log_2 \frac{4}{5} - \frac{1}{5} \log_2 \frac{1}{5} \right) + \frac{6}{15} \times \left(-\frac{2}{6} \log_2 \frac{2}{6} - \frac{4}{6} \log_2 \frac{4}{6} \right) + \frac{4}{15} \times \left(-\frac{4}{4} \log_2 \frac{4}{4} \right) = 0.608$$

③计算信息增益

$$g(D|A) = Inf or(D) - Inf or(D|A) = 0.083$$

$$g(D|B) = Inf or(D) - Inf or(D|B) = 0.324$$

$$g(D|C) = Inf or(D) - Inf or(D|C) = 0.020$$

$$g(D|E) = Inf or(D) - Inf or(D|E) = 0.363$$

分类的相关知识：

- 3、信息增益率

信息增益率是指按照某一特征进行划分的信息增益与训练集关于这个特征的信息熵的比值。：

$$g_r(D, A) = \frac{g(D|A)}{SplitInfor_A(D)}$$

其中：

$$SplitInfor_A(D) = - \sum_{j=1}^n \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right)$$

例 7.2 信息增益率的计算

基于例7.1的数据，计算按照每个特征进行划分的信息增益率。

解：①根据例7.1计算出的按照每个特征划分的信息增益， A 代表特征“学历”， B 代表特征“婚否”， C 代表特征“是否有车”， E 代表特征“收入水平”，计算 $SplitInfor_A(D)$ 。

$$SplitInfor_A(D) = -\frac{5}{15} \times \log_2 \frac{5}{15} - \frac{5}{15} \times \log_2 \frac{5}{15} - \frac{5}{15} \times \log_2 \frac{5}{15} = 1.585$$

$$SplitInfor_B(D) = -\frac{10}{15} \times \log_2 \frac{10}{15} - \frac{5}{15} \times \log_2 \frac{5}{15} = 0.918$$

$$SplitInfor_C(D) = -\frac{9}{15} \times \log_2 \frac{9}{15} - \frac{6}{15} \times \log_2 \frac{6}{15} = 0.971$$

$$SplitInfor_E(D) = -\frac{5}{15} \times \log_2 \frac{5}{15} - \frac{6}{15} \times \log_2 \frac{6}{15} - \frac{4}{15} \times \log_2 \frac{4}{15} = 1.566$$

②按照公式(7-5)计算信息增益率。

$$g_r(D, A) = \frac{0.083}{1.585} = 0.052$$

$$g_r(D, B) = \frac{0.324}{0.918} = 0.331$$

$$g_r(D, C) = \frac{0.020}{0.971} = 0.021$$

$$g_r(D, E) = \frac{0.363}{1.566} = 0.232$$

分类的相关知识：

- 4、基尼系数

基尼指数是度量数据分区或者训练数据的不纯度。

$$Gini(D) = 1 - \sum_{i=1}^m p_i^2$$

其中 p_i 是数据集合 D 中任何一个记录属于 C_i 类的概率，可通过 $\frac{|C_{i,D}|}{|D|}$ 进行计算， $|C_{i,D}|$ 是 D 中属于 C_i 类的集合的记录个数， $|D|$ 是所有记录的个数。如果所有的记录都属于同一个类，则 $p_i=1$ ， m 是分区数量。基尼指数考虑的是二分化，即将某一特征中的数值分为两个子集，然后进行划分。如果按照特征 A 作为数据的二元划分准则将 D 分成 D_1 和 D_2 ，则 D 的基尼指数为：

$$Gini_A(D) = \frac{|D_1|}{|D|} Gini(D_1) + \frac{|D_2|}{|D|} Gini(D_2)$$

对于属性 A 的二元划分导致的不纯度降低为

$$\Delta Gini(A) = Gini(D) - Gini_A(D) \quad (7-9)$$

例7.3 计算属性的不纯度降低值

根据表7-1中的数据计算“学历”属性的基尼指数。

解 ①使用基尼指数计算公式(7-7)计算 D 的不纯度：

$$Gini(D) = 1 - \left(\frac{9}{15}\right)^2 - \left(\frac{6}{15}\right)^2 = 0.48$$

②计算属性“学历”的基尼指数。此特征有三个取值：“专科”、“本科”、“硕士”。所以划分值有三个，即三种划分集合，分别为：

以“专科”划分：{专科}、{本科、研究生}。

以“本科”划分：{本科}、{专科、研究生}。

以“研究生”划分：{研究生}、{专科、本科}。

考虑集合{研究生}、{本科，专科}， D 被划分成两个部分，基于这样的划分计算基尼指数为：

$$\begin{aligned} Gini_{\{本科, 专科\}, \{研究生\}}(D) &= \frac{10}{15}Gini(D_1) + \frac{5}{15}Gini(D_2) \\ &= \frac{10}{15} \times (1 - (\frac{1}{2})^2 - (\frac{1}{2})^2) + \frac{5}{15} \times (1 - (\frac{1}{5})^2 - (\frac{4}{5})^2) = 0.44 \end{aligned}$$

例7.3 计算属性的不纯度降低值

根据表7-1中的数据计算“学历”属性的基尼指数。

解

类似地可以求出属性“学历”其余子集的基尼指数：

以“专科”划分的基尼指数为：

$$\begin{aligned} Gini_{\{\text{本科}, \text{研究生}\}, \{\text{专科}\}}(D) &= \frac{10}{15} Gini(D_1) + \frac{5}{15} Gini(D_2) \\ &= \frac{10}{15} \times (1 - (\frac{3}{10})^2 - (\frac{7}{10})^2) + \frac{5}{15} \times (1 - (\frac{2}{5})^2 - (\frac{3}{5})^2) = 0.44 \end{aligned}$$

以“本科”划分的基尼指数为：

$$\begin{aligned} Gini_{\{\text{专科}, \text{研究生}\}, \{\text{本科}\}}(D) &= \frac{10}{15} Gini(D_1) + \frac{5}{15} Gini(D_2) \\ &= \frac{10}{15} \times (1 - (\frac{2}{5})^2 - (\frac{3}{5})^2) + \frac{5}{15} \times (1 - (\frac{2}{5})^2 - (\frac{3}{5})^2) = 0.48 \end{aligned}$$

选择基尼指数最小值0.44作为属性“学历”的基尼指数，

因此属性“学历”的不纯度降低值为：

$$\Delta Gini(A) = Gini(D) - Gini_A(D) = 0.48 - 0.44 = 0.04$$

同样可以求出每个属性的基尼指数及不纯度降低值。

分类的相关知识：

- 5、过拟合

通常，模型为了较好拟合训练数据会变得比较复杂，模型复杂的表现就是参数过多。虽然模型在训练数据上有较好的效果，但是对未知的测试数据可能结果会不好，这种现象叫做过拟合。



感谢指导！

THANKS FOR YOUR ATTENTION