



第7章 分类

目录 CONTENTS

7.1

分类概述

7.2

决策树

7.3

朴素贝叶斯分类

7.4

惰性学习法

7.5

神经网络

7.6

分类模型的评估



Chapter 7.3

朴素贝叶斯分类

– 贝叶斯定理

设 X 是一个类标号未知的数据样本， H 表示一个假设：数据样本 X 属于某个特定的类 C 。要求确定 $P(H|X)$ ，即给定观测数据样本 X 的情况下假设 H 成立的概率。

- 例如， X 是一位35岁的顾客，其收入为4万美元。令 H 为某种假设，如顾客将购买计算机。

– $P(H|X)$ 是后验概率

- 例如，顾客 X 将购买计算机的概率。

– $P(H)$ (prior probability)是先验概率

- 例如，顾客将购买电脑的概率，无论年龄和收入等等。

– $P(X)$ 是 X 的先验概率

- 例如，顾客集合中年龄为35岁且收入为4万美元的概率

– $P(X|H)$ 是后验概率

- 例如，已知顾客 X 将计算机，该顾客是年龄为35岁，收入为4万美元的概率

– 贝叶斯定理：

$$P(H | \mathbf{X}) = \frac{P(\mathbf{X} | H)P(H)}{P(\mathbf{X})} = P(\mathbf{X} | H) \times P(H) / P(\mathbf{X})$$

- 朴素贝叶斯分类基本思想：

设输入空间是 n 维向量的集合，取其中 m 个样本做训练数据集，表示为 $S = \{S_1, S_2, \dots, S_m\}$ ，其中每个样本 S_i 都是一个 n 维向量 $\{x_1, x_2, \dots, x_n\}$ ；输出空间是类标记的集合，表示为 $Y = \{C_1, C_2, \dots, C_k\}$ ，取自输入空间的每个样本 S_i 都与输出空间中的一个类 C_i 相对应。当给定另外一个类别未知的数据样本 X ，可以把 X 分到后验概率最大的类中，也就是用最高的条件概率 $P(C_i|X)$ 来预测 X 的类别。

- 朴素贝叶斯分类基本思想：
- 根据贝叶斯定理，后验概率计算过程为

$$P(C_i | \mathbf{X}) = \frac{P(\mathbf{X} | C_i) P(C_i)}{P(\mathbf{X})}$$

- $P(\mathbf{X})$ 为常数，使下式最大化

$$P(C_i | \mathbf{X}) = P(\mathbf{X} | C_i) P(C_i)$$

- 其中：

$$P(C_i) = |C_i| / m$$

- 实际中，朴素贝叶斯给出一个较强的条件独立性假设

$$P(\mathbf{X} | C_i) = P(X^{(1)} = x_1, \dots, X^{(n)} = x_n | C_i) = \prod_{j=1}^n P(x_j | C_i)$$

朴素贝叶斯分类过程：

朴素贝叶斯法分类时，假设输入变量都是条件独立的，通过在训练数据上学习得到模型，计算出每个类别的先验概率和条件概率，依照模型计算后验概率 $P(C_i|X)$ ，将后验概率最大的类作为输入变量所属的类输出。经过上述分析，朴素贝叶斯分类器可表示为：

$$y = \underset{C_i}{\operatorname{arg\,max}} P(C_i) \prod_j P(x_j|C_i)$$

朴素贝叶斯分类算法：

算法：朴素贝叶斯分类算法。

输入：

- 数据集 S 是训练元组和对应类标号的集合；

- 待分类的数据 X

输出：数据 X 所属的类别

方法：

根据数据集 S 计算每个类别 C_i 的先验概率 $P(C_i)$ 。

根据数据集 S 计算各个独立特征 $X^{(j)}$ 在分类中的条件概率 $p(X^{(j)}|C_i)$ 。

对于特定的输入数据 X ，计算其相应属于特定分类的条件概率 $p(C_i|X)$ 。

选择条件概率最大的类别作为该输入数据 X 的类别返回。

例.朴素贝叶斯分类算法实例：

训练数据如表7-7所示，其中 $X^{(1)}$ 和 $X^{(2)}$ 为特征，取值分别来自特征集合 $A_1 = \{1, 2, 3\}$, $A_2 = \{S, P, Q\}$ ， C 为类标记， $C = \{1, -1\}$ ，即有1和-1两类。根据训练数据学习一个朴素贝叶斯分类器并确定 $X = (2, S)^T$ 的类标记。

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	P	P	S	S	S	P	P	Q	Q	Q	P	P	Q	Q
C	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	-1

- 计算先验概率：

$$P(C = 1) = \frac{9}{15}, P(C = -1) = \frac{6}{15}$$

- 计算条件概率：

$$P(X^{(1)} = 1|C = 1) = \frac{2}{9}, P(X^{(1)} = 2|C = 1) = \frac{3}{9}, P(X^{(1)} = 3|C = 1) = \frac{4}{9}$$

$$P(X^{(2)} = S|C = 1) = \frac{1}{9}, P(X^{(2)} = P|C = 1) = \frac{4}{9}, P(X^{(2)} = Q|C = 1) = \frac{4}{9}$$

$$P(X^{(1)} = 1|C = -1) = \frac{3}{6}, P(X^{(1)} = 2|C = -1) = \frac{2}{6}, P(X^{(1)} = 3|C = -1) = \frac{1}{6}$$

$$P(X^{(2)} = S|C = -1) = \frac{3}{6}, P(X^{(2)} = P|C = -1) = \frac{2}{6}, P(X^{(2)} = Q|C = -1) = \frac{1}{6}$$

- 对于给定的 $x = (2, S)^T$ ，依照分类器模型计算：

$$P(C = 1|X) = P(C = 1) \cdot P(X^{(1)} = 2|C = 1) \cdot P(X^{(2)} = S|C = 1) = \frac{9}{15} \cdot \frac{3}{9} \cdot \frac{1}{9} = \frac{1}{45}$$

$$P(C = -1|X) = P(C = -1) \cdot P(X^{(1)} = 2|C = -1) \cdot P(X^{(2)} = S|C = -1) = \frac{6}{15} \cdot \frac{2}{6} \cdot \frac{3}{6} = \frac{1}{15}$$

$X = (2, S)^T$ 属于-1类别的概率最大，依照朴素贝叶斯中概率最大化准则，该分类器输出的类标记为-1。



感谢指导！

THANKS FOR YOUR ATTENTION