



第7章 分类

目录 CONTENTS

7.1

分类概述

7.2

决策树

7.3

朴素贝叶斯分类

7.4

惰性学习法

7.5

神经网络

7.6

分类模型的评估



Chapter 7.4

惰性学习法

惰性学习法并不急于在收到测试对象之前构造分类模型。当接收一个训练集时，惰性学习法只是简单地存储或稍加处理每个训练对象，直到测试对象出现，才构造分类模型。主要包括以下几种方法：

- K最邻近分类法 (KNN)
- 局部加权回归法
- 基于案例的推理

K邻近算法的思想

从训练集中找出 k 个最接近测试对象的训练对象，再从这 k 个对象中确定主导类别，将此类别值赋给测试对象。

假设训练对象有 n 个属性，每个对象由 n 维空间的一个点表示，则整个训练集处于 n 维模式空间中。每当给定一个测试对象 c ，K近邻算法计算 c 到每个训练对象的距离，并找到最接近 c 的 k 个训练对象，这 k 个训练对象就是 c 的 k 个“最近邻”。然后，将测试对象 c 指派到“最近邻”中对象数量最多的类。

当 $k=1$ 时，测试对象被指派到与它最近的训练对象所属的类。

K邻近算法的描述

K近邻算法进行分类时需要考虑4个关键要素：

- ①被标记的训练对象的集合，即训练集，用来决定一个测试对象的类别。
- ②距离（或相似度）指标，用来计算对象间的邻近程度。一般情况下，采用欧几里德距离或曼哈顿距离。
对于给定的具有 n 个属性的对象 x 和 y ，欧几里德距离与曼哈顿距离分别由公式（7-19）和公式（7-20）计算，其中 $x_k - y_k$ 是两个对象属性 k 对应值的差。

$$d(x, y) = \sqrt{\sum_{k=1}^n (x_k - y_k)^2} \quad (7-19)$$

$$d(x, y) = \sum_{k=1}^n |x_k - y_k| \quad (7-20)$$

- ③最近邻的个数 k 。 k 的值可以通过实验来确定。对于小数据集，取 $k=1$ 常常会得到比其他值更好的效果，而在样本充足的情况下，往往选择较大的 k 值。
- ④从 k 个“最近邻”中选择目标类别的方法。

例7.8 K近邻算法实例

iris.arff数据集包含了150条关于花的数据，这些数据被等分为三类Iris物种: Setosa、Versicolor和Virginica，每朵花的数据描述四项特征: 花萼长度、花萼宽度、花瓣长度和花瓣宽度。表7-8和表7-9分别是iris.arff训练数据与测试数据的示例。

表7-8 Iris物种的训练数据

ID	花萼长度	花萼宽度	花瓣长度	花瓣宽度	物种
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
3	5.0	3.4	1.5	0.2	Setosa
4	7.0	3.2	4.7	1.4	Versicolor
5	6.9	3.1	4.9	1.5	Versicolor
6	6.7	3.1	4.4	1.4	Versicolor
7	6.3	2.8	5.1	1.5	Virginica
8	6.9	3.1	5.4	2.1	Virginica
9	7.2	3.0	5.8	1.6	Virginica

表7-9 Iris物种的测试数据

ID	花萼长度	花萼宽度	花瓣长度	花瓣宽度	物种
*	6.4	3.1	5.5	1.8	?

解：目标是确定表7-9中测试数据的物种。选取欧几里德距离来计算该测试对象与每个训练对象之间的距离（保留两位小数）：

$$d(*, 1) = \sqrt{(6.4 - 5.1)^2 + (3.1 - 3.5)^2 + (5.5 - 1.4)^2 + (1.8 - 0.2)^2} = 4.61$$

$$d(*, 2) = \sqrt{(6.4 - 4.9)^2 + (3.1 - 3.0)^2 + (5.5 - 1.4)^2 + (1.8 - 0.2)^2} = 4.65$$

$$d(*, 3) = \sqrt{(6.4 - 5.0)^2 + (3.1 - 3.4)^2 + (5.5 - 1.5)^2 + (1.8 - 0.2)^2} = 4.54$$

$$d(*, 4) = \sqrt{(6.4 - 7.0)^2 + (3.1 - 3.2)^2 + (5.5 - 4.7)^2 + (1.8 - 1.4)^2} = 1.08$$

$$d(*, 5) = \sqrt{(6.4 - 6.9)^2 + (3.1 - 3.1)^2 + (5.5 - 4.9)^2 + (1.8 - 1.5)^2} = 0.84$$

$$d(*, 6) = \sqrt{(6.4 - 6.7)^2 + (3.1 - 3.1)^2 + (5.5 - 4.4)^2 + (1.8 - 1.4)^2} = 1.21$$

$$d(*, 7) = \sqrt{(6.4 - 6.3)^2 + (3.1 - 2.8)^2 + (5.5 - 5.1)^2 + (1.8 - 1.5)^2} = 0.59$$

$$d(*, 8) = \sqrt{(6.4 - 6.9)^2 + (3.1 - 3.1)^2 + (5.5 - 5.4)^2 + (1.8 - 2.1)^2} = 0.59$$

K邻近算法伪代码

算法：K近邻分类算法。

输入：

数据集D是具有n个训练元组和对应类标号的集合；

近邻数目k；

待分类数据X

输出：数据X所属的类别

K邻近算法伪代码

方法：

从数据集D中取 $A[1] \sim A[k]$ 作为X的初始近邻，计算与待分类数据X间的欧式距离 $d(X, A[i])$,
 $i=1,2,\dots,k$;

按 $d(X, A[i])$ 升序排序，得到最远样本与X间的距离 $\text{Dist} = \max\{d(X, A[j]) | j = 1, 2, \dots, k\}$;

for ($i=k+1$; $i \leq n$; $i++$)

 计算 $a[i]$ 与X间的距离 $d(X, A[i])$;

 if($d(X, A[i]) < \text{Dist}$)

 then 用 $A[i]$ 代替最远样本;

 按照 $d(X, A[i])$ 升序排序，得到最远样本与X间的距离 $\text{Dist} = \max\{d(X, A[j]) | j = 1, 2, \dots, k\}$;

end for

计算前k个样本 $A[i]$ ($i=1, 2, \dots, k$) 所属类别的概率，具有最大概率的类别即为数据X的类。

K邻近算法性能

K邻近算法的性能受一些关键因素的影响

- **K值的选择**：如果k值选择过小，结果会对噪声点的影响特别敏感；反之，k值选择过大，那么近邻中就可能包含太多种类别的点。
- **目标类别的选择**：最简单的做法是如之前所述的投票方式，然后对每个投票依据距离进行加权
- **距离指标的选择**：最佳测距方法应该满足这种性质：对象之间距离越小，它们同属于一个类别的可能性越大。



感谢指导！

THANKS FOR YOUR ATTENTION