



第7章 分类

目录 CONTENTS

7.1

分类概述

7.2

决策树

7.3

朴素贝叶斯分类

7.4

惰性学习法

7.5

神经网络

7.6

分类模型的评估



Chapter 7.6

分类模型评估

1. 分类模型的评价指标

二分类问题，即分类目标只有两类，正类（positive）即感兴趣的主要类和负类（negative）即其他类，正例即为正类的实例或元组，负例即为负类的实例或元组。

表7-13 二分类的混淆矩阵

实例分类 \ 预测类	正类	负类	合计
正类	TP	FN	P
负类	FP	TN	N
合计	P'	N'	P+N

- ①真正例(True Positives, TP):被正确地划分为正类的实例数，即实际为正例且被分类器划分为正例的实例数。
- ②假正例(False Positives, FP):被错误地划分为正类的实例数，即实际为负例但被分类器划分为正例的实例数。
- ③假负例(False Negatives, FN):被错误地划分为负类的实例数，即实际为正例但被分类器划分为负例的实例数。
- ④真负例(True Negatives, TN):被正确地划分为负类的实例数，即实际为负例且被分类器划分为负例的实例数。

1. 分类模型的评价指标

① 准确率 (accuracy)

又称为分类器的总体识别率，准确率表示分类器对各类元组的正确识别情况，它定义为被正确分类的元组数占预测总元组数的百分比，计算公式如 (7-59) 所示。

$$\text{accuracy} = \frac{TP+TN}{P+N} \quad (7-59)$$

② 错误率 (error rate)

又称为误分辨率，错误率表示分类器对各类元组的错误识别情况，是 $1-\text{accuracy}$ ，具体计算公式如 (7-60) 所示。

$$\text{error rate} = \frac{FP+FN}{P+N} \quad (7-60)$$

1. 分类模型的评价指标

③ 特效性 (specificity)

又称为真负例识别率(True Negative Rate, TNR), 特效性表示分类器对负元组的正确识别情况, 它定义为正确识别的负元组数量占实际为负元组总数的百分比, 计算公式如(7-61)所示。

$$\text{specificity} = \frac{TN}{N} \quad (7-61)$$

④ 灵敏度 (sensitivity)

灵敏度也被称为真正例识别率(True Positive Rate, TPR), 即正确识别的正元组的百分比, 衡量了分类器对正类的识别能力, 具体计算公式如(7-63)所示。

$$\text{sensitivity} = \frac{TP}{P} \quad (7-63)$$

1. 分类模型的评价指标

⑤精度 (precision)

精度可以看做精确性的度量，即正确识别的正元组数量占预测为正元组总数的百分比。

具体计算公式如 (7-62) 所示。

$$precision = \frac{TP}{TP+FP} = \frac{TP}{P'} \quad (7-62)$$

⑥召回率 (recall)

召回率用来评价模型的灵敏度和识别率，是完全性的度量，即正元组被标记为正类的百分比，即为灵敏度（或真正例率），具体计算公式如 (7-64) 所示。

$$recall = \frac{TP}{TP+FN} = \frac{TP}{P} \quad (7-64)$$

1. 分类模型的评价指标

⑦ 综合评价指标（F度量）

将精度和召回率组合到一个度量中，即为F度量（又称为 F_1 分数或F分数）和 F_β 度量的方法，具体计算公式如（7-65）（7-66）所示。

$$F = \frac{2 \times \text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \quad (7-65)$$

$$F_\beta = \frac{(1 + \beta^2) \times \text{precision} \times \text{recall}}{\beta^2 \times \text{precision} + \text{recall}} \quad (7-66)$$

其中， β 是非负实数。F度量是精度和召回率的均值。它赋予精度和召回率相等的权重。 F_β 度量是精度和召回率加权度量。它赋予召回率权重是赋予精度的 β 倍。通常使用的 F_β 是 F_2 （它赋予召回率权重是精度的2倍）和 $F_{0.5}$ （它赋予精度的权重是召回率的2倍）。

1. 分类模型的评价指标

⑧假负例识别率

假负例识别率(False Negative Rate , FNR) , 它定义为错误识别为负类的正元组数量占实际为正元组总数的百分比 , 具体计算公式如 (7-67) 所示。

$$FNR = \frac{FN}{TP+FN} = \frac{FN}{P} \quad (7-67)$$

⑨假正例识别率

假正例识别率(False Positive Rate , FPR) , 它定义为错误识别为正类的负元组数量占实际为负元组总数的百分比 , 具体计算公式如 (7-68) 所示。

$$FPR = \frac{FP}{FP+TN} = \frac{FP}{N} \quad (7-68)$$

1. 分类模型的评价指标

例7.10 分类模型评价指标的计算

混淆矩阵如表7-14所示，计算准确率、错误率、特效性等评价指标。

表7-14混淆矩阵实例

实例分类 \ 预测类	正类	负类	合计
正类	150	40	190
负类	60	250	310
合计	210	290	500

1. 分类模型的评价指标

解：

①计算准确率。

$$accuracy = \frac{150+250}{500} \times 100\% = 80\%$$

②计算错误率。

$$errorrate = 1 - accuracy = 20\%$$

③计算特效性。

$$specificity = \frac{250}{310} \times 100\% \approx 80.65\%$$

④计算灵敏度。

$$sensitivity = \frac{150}{190} \times 100\% = 78.95\%$$

⑤计算精度。

$$precision = \frac{150}{150 + 60} = \frac{150}{210} \times 100\% = 71.43\%$$

1. 分类模型的评价指标

⑥计算召回率。

$$recall = \frac{150}{150+40} = \frac{150}{190} \times 100\% = 78.94\%$$

⑦计算F度量。

$$F = \frac{2 \times 71.43\% \times 78.95\%}{71.43\% + 78.95\%} = 0.75002$$

⑧计算假负例识别率。

$$FNR = \frac{40}{150 + 40} = \frac{40}{190} \times 100\% = 21.05\%$$

⑨计算假正例识别率。

$$FPR = \frac{60}{250 + 60} = \frac{60}{310} \times 100\% = 19.35\%$$

1. 分类模型的评价指标

⑩ ROC曲线

ROC曲线(Receiver Operating Characteristic Curve)是指接收者操作特征曲线，是反映灵敏度和特效性连续变量的综合指标，是用构图法揭示灵敏度和特效性的相互关系




图7-76 ROC曲线

1. 分类模型的评价指标

ROC曲线图中的四点一线

- ① $(0, 1)$: 即 $FPR=0$, $TPR=1$ 。此时假负类率为0, 假正类率为0, 表示该分类器正确分类了所有样本;
- ② $(1, 0)$: 即 $FPR=1$, $TPR=0$ 。此时真负类率为0, 真正类率为0, 表示该分类器避开了所有的正确答案;
- ③ $(0, 0)$: 即 $FPR=0$, $TPR=0$ 。此时假负类率为0, 真正类率为0, 表示该分类器将所有样本划分为负类;
- ④ $(1, 1)$: 即 $FPR=1$, $TPR=1$ 。此时真负类率为0, 假正类率为0, 表示该分类器将所有样本划分为正类;
- ⑤ 虚线 $y=x$: 该线上的点表示一个采用随机猜测策略的分类器结果, 表示该分类器随对于一半样本划分为正类, 另一半为负类。




图7-76 ROC曲线

1. 分类模型的评价指标

表7-15 测试样本数据集

样本编号	实际分类	概率
1	正类	0.9
2	正类	0.8
3	负类	0.6
4	正类	0.55
5	正类	0.54
6	负类	0.53
7	正类	0.525
8	正类	0.52
9	负类	0.505
10	正类	0.5
11	正类	0.38
12	负类	0.37
13	正类	0.365
14	负类	0.36
15	负类	0.357
16	负类	0.355
17	正类	0.355
18	负类	0.35
19	负类	0.3
20	负类	0.1

1. 分类模型的评价指标

表7-15 测试样本数据集

样本编号	实际分类	概率	TP	FP	TN	FN	TPR	FPR
1	正类	0.9	1	0	10	9	0.1	0
2	正类	0.8	2	0	10	8	0.2	0
3	负类	0.6	2	1	9	8	0.2	0.1
4	正类	0.55	3	1	9	7	0.3	0.1
5	正类	0.54	4	1	9	6	0.4	0.1
6	负类	0.53	4	2	8	6	0.4	0.2
7	正类	0.525	5	2	8	5	0.5	0.2
8	正类	0.52	6	2	8	4	0.6	0.2
9	负类	0.505	6	3	7	4	0.6	0.3
10	正类	0.5	7	3	7	3	0.7	0.3
11	正类	0.38	8	3	7	2	0.8	0.3
12	负类	0.37	8	4	6	2	0.8	0.4
13	正类	0.365	9	4	6	1	0.9	0.4
14	负类	0.36	9	5	5	1	0.9	0.5
15	负类	0.357	9	6	4	1	0.9	0.6
16	负类	0.355	10	7	3	0	1	0.7
17	正类	0.355	10	7	3	0	1	0.7
18	负类	0.35	10	8	2	0	1	0.8
19	负类	0.3	10	9	1	0	1	0.9
20	负类	0.1	10	10	0	0	1	1

1. 分类模型的评价指标




图7-77 ROC曲线实例

1. 分类模型的评价指标

⑪ AUC

AUC (Area Under Curve) 被定义为ROC曲线下的面积，这个面积的数值不会大于1。又由于ROC曲线一般都处于 $y=x$ 这条直线的上方，所以AUC的取值范围在0.5和1之间。AUC值是一个概率值，当随机挑选一个正样本以及一个负样本，当前的分类算法根据计算得到的值将这个正样本排在负样本前面的概率就是AUC值。当然，AUC值越大，当前的分类算法越有可能将正样本排在负样本前面，即能够更好的分类。

- $AUC = 1$ ，是完美分类器，采用这个预测模型时，不管设定什么阈值都能得出完美预测。绝大多数预测的场合，不存在完美分类器。
- $0.5 < AUC < 1$ ，优于随机猜测。这个分类器（模型）妥善设定阈值的话，能有预测价值。
- $AUC = 0.5$ ，跟随机猜测一样（例：丢铜板），模型没有预测价值。
- $AUC < 0.5$ ，比随机猜测还差；但只要总是反预测而行，就优于随机猜测。

2. 交叉验证

- 交叉验证(Cross Validation , CV)是用来验证分类器性能的一种统计分析方法，基本思想是在某种意义下将原始数据(dataset)进行分组，一部分做为训练集(train set)，另一部分做为验证集(validation set)。首先用训练集对分类器进行训练，再利用验证集来测试训练得到的模型(model)，以此来做为评价分类器的性能指标。
- 交叉验证用于评估模型的预测性能，尤其是训练好的模型在新数据上的表现，可以在一定程度上减小过拟合。交叉验证还可以从有限的数据中获取尽可能多的有效信息。

2. 交叉验证

常见交叉验证的方法有以下几种。

①留出法(**holdout cross validation**)

将原始数据随机分为两组独立的数据集，一组做为训练集，一组做为验证集，通常2/3的数据分配到训练集，1/3的数据分配到验证集。利用训练集训练分类器，利用验证集验证模型，分类模型的准确率使用验证集估计。

2. 交叉验证

② k折交叉验证(k-fold Cross Validation)

- 初始数据随机地划分成k个互不相交的子集或“折” $D_1, D_2, \dots, D_k$ ，每个折的大小大致相等。训练和验证进行k次。在第i次迭代，分组 D_i 用做验证集，其余的分组一起用作训练模型。
即，在第一次迭代，子集 $D_2, \dots, D_k$ 一起作为训练集，得到第一个模型，并在 D_1 上验证；第二次迭代在子集 $D_1, D_3, \dots, D_k$ 上训练，并在 D_2 上验证；如此下去迭代k次，得到k个模型。此方法中每个样本用于训练的次数相同，并且用于验证一次。对于分类，准确率估计是k次迭代正确分类的元组总数除以初始数据中的元组总数，即k个分类模型验证集分类准确率的平均值。
- k一般大于等于2，实际操作时一般从3开始取，**10折交叉验证最常用**。当数据量小的时候，k可以设大一些，这样训练集占整体比例就比较大，同时训练的模型个数也增多；数据量大的时候，k可以设小一些。

2. 交叉验证

③ 留一法(Leave-One-Out Cross Validation)

留一法是 k 等于 N (N 为样本总数) 时的 **k 折交叉验证**，即每个样本单独作为验证集，其余的 $N-1$ 个样本作为训练集。留一法得到 N 个模型，用这 N 个模型最终的验证集的分类准确率的平均数作为分类器的性能指标。

3. 自助法

- 在统计学中，自助法（Bootstrap Method，Bootstrapping或自助抽样法）是一种从给定训练集中有放回的均匀抽样，也就是说，每当选中的一个样本，它等可能地被再次选中并被再次添加到训练集中。
- 有多种自助方法，最常用的是.632自助法。假设给定的数据集包含 d 个样本。该数据集有放回地抽样 d 次，产生 d 个样本的训练集。这样原数据样本中的某些样本很可能在该样本集中出现多次。没有进入该训练集的样本最终形成验证集。显然每个样本被选中的概率是 $1/d$ ，因此未被选中的概率就是 $(1-1/d)$ ，这样一个样本在训练集中没出现的概率就是 d 次都未被选中的概率，即 $(1 - \frac{1}{d})^d$ 。当 d 趋于无穷大时，这一概率趋近于 $e^{-1} - 1 = 0.368$ ，所以留在训练集中的样本大概就占原来数据集的63.2%。

3. 自助法

- 可以重复抽样过程 k 次，其中在每次迭代中，使用当前的验证集得到从当前自助样本得到的模型的准确率估计。模型的总体准确率估计如公式（7-69）所示。

$$accuracy(M) =$$

$$\sum_{i=1}^k (0.632 \times accuracy(M_i)_{validation_set} + 0.368 \times accuracy(M_i)_{train_set}) \quad (7-69)$$

其中， $accuracy(M_i)_{validation_set}$ 是自助样本 i 得到的模型用于验证集的准确率。

$accuracy(M_i)_{train_set}$ 是自助样本 i 得到的模型用于原数据元组集的准确率。



感谢指导！

THANKS FOR YOUR ATTENTION